确定性智能体评测中的失败归因

比较路径与匹配合同的重放研究

匿名作者
匿名单位

2026 年 10 月 14 日

摘要

智能体评测检查通过，可能源于实现正确、比较路径对故障不敏感，或实际谓词与声称性质不一致。本文对观察者证据管线和固定版本的外部辅助评分器开展回顾性、无模型审计。在原门禁实际使用的投影、上下文与请求载荷链上注入一类作者设计的隐藏状态泄漏故障，并干预门禁的输入转发。12 个合成时间线族包含 288 个嵌套条件，其中 216 个含状态断言的比较臂在三个产物层均拒绝该故障。仅改变故障函数的关键字参数名称，会改变基于签名的充分性标签，却不改变失败记录。相反，在门禁中丢弃扰动输入，会使同一泄漏实现得到通过判决，九个可见信息正控仍全部通过；恢复转发后，失败恢复。外部匹配器的六个词法探针对中有三个改变命中判决，但不据此认定语义等价或上游错误。目标字段对齐和评分聚合控制进一步区分匹配行为、标签一致性与检查点后果。本文贡献是包含健康、故障和恢复控制的可复现失败归因案例，不是通用检出率估计、新的非干扰理论或语言模型质量评测。

关键词 智能体评测；故障注入；非干扰测试；比较有效性；时间证据；可复现性

1 引言

智能体在动态环境中能够知道的内容，比世界的全局状态更窄。观察者离开房间后，房间可能已经安静；记得曾经听到声音，不等于能够断言现在仍有声音。评测既要区分观察者可获得的事实和评测者独享的事实，也要区分被测智能体的失败和测量工具的失败。用过期目标字段计算出的分数不能回答新目标的问题；没有收到干预输入的比较，也不能检验该干预的影响。

后一个区分是本研究的重点。观察者证据项目的早期解释认为，安全投影器有意忽略隐藏输入，因此隐藏孪生输出相等的检查无法检出故障。该解释混淆了健康实现和比较门禁：门禁只要转发隐藏扰动，即使安全实现忽略它，也可能拒绝读取它的替换实现。本文在实际执行链上检验这种区别，不从函数签名推断检出能力。同一项目曾将外部匹配器的词法差异描述为违反已认证表示等价性；输入材料并未建立这种认证。本文保留实测行为，收窄其解释。

研究对象是生成观察者可见投影、简化模型上下文和序列化请求载荷的确定性链。我们分别干预投影器及其调用门禁。固定版本的外部辅助评分器提供另一种归因问题，涉及词法匹配、目标标签及泄漏指标聚合。两部分均没有新增模型调用。

研究问题如下。**RQ1** 实际比较能否区分健康的隐藏状态不变性与依赖隐藏状态的投影器？**RQ2** 参数命名启发式及可见信息正控通过，是否足以证明隐藏故障比较有效？**RQ3** 没有独立语义关系或检查点后果证据时，匹配器探针对能够说明什么？

贡献包括：同链泄漏注入及健康、签名改名、输入丢弃和恢复控制；区分实现行为、干预传递和报告标签的归因分析；公开源代码提取件、全部 12 族的不透明衍生夹具、逐比较报告和固定评分器的合成探针。证据支持具体反例，不支持故障发生率、全面变异充分性、真实感知质量或模型排名。

2 背景与相关研究

2.1 时间与观察者证据

事实有效时间与系统获知时间的区分源于时间数据库研究 [11]。W3C 语义传感器网络本体区分现象时间与结果时间 [13]。本文将既有概念用于观察者时间线，不将时间有效性或来源追溯作为新概念。

LongMemEval 考查长期对话记忆中的时间推理、知识更新和弃答 [14]；TimeChara 考查特定时间点的角色知识 [1]。这些任务说明可获得证据与全局信息的区分具有应用意义。本文则检验模型能力评估前的确定性产物构建。三值可回答性同样不是新概念，FEVER 包含信息不足类别 [12]。本实现的投影器输出 current 和 history，unknown 可回答性仍在评测侧；本文没有实现完整三路回答机制。

2.2 非干扰、空洞性与基于故障的测试

非干扰限制不同信息域之间的影响 [5]；自组合通过成对执行分析关系性质 [2]，非干扰测试也有直接研究 [6]。隐藏孪生输出比较属于既有关系测试。有限执行能够给出反例，不能证明所有输入上的非干扰。

空洞性检测关注通过却未有效检验预期义务的规范 [3]。模型检查中的形式定义不能无差别套用于一切弱检查。本文仅将指定输入域内恒真的谓词称为逻辑恒真；将干预在比较计算之前被丢弃称为比较输入路径失败。覆盖不足、阈值宽松和缺乏语义依据是不同问题。

变异测试考查测试对人为故障的响应 [8]。本文采用这一思路，但不是代表性变异测试活动。只有一类泄漏投影语义和一类门禁故障；第二种签名包装相同泄漏语义。不同时间线比较臂是在不同输入上反复检验同一故障，不能计为独立变异体。

2.3 蜕变关系与评分合同

蜕变测试在缺乏传统预言机时检验相关输入输出的关系 [10, 4]。关系本身仍需依据。全角数字在某些任务中可能保留人类阅读含义；插入逗号或改变周边文本可能改变含义。整词匹配也可能是有意设计。判决变化不能单独决定哪一侧正确。

因此六个作者编写的成对输入被称为词法表示探针。本文另设明确受保护值的目标对齐控制，以及明确消费模式集合的聚合控制，避免将匹配器行为上升为公开基准分数错误。本文不声称提出新的变异框架，也不声称穷尽评测工具研究。

3 研究设计与对象

3.1 范围与选取

主要对象是一个项目既有的证据评测链、封存创作语料、孪生门禁及历史报告。研究是在报告解释受到质疑后选取的；故障、探针和分析在阅读实现后设计。本文是回顾性探索研究，没有预注册、随机选取被审计对象或留出故障集。“封存”仅表示语料此前已冻结，不使后续审计成为确认性研究。

12 个时间线族共享一个创作程序。九族具有状态断言及隐藏事件边界，三族为不适用该干预的通信族。每族包含三种刷新策略、两种投影策略和四个查询：

$$12 \times 3 \times 2 \times 4 = 288\text{个嵌套条件}.$$

隐藏状态干预适用于九个状态族：

$$9 \times 3 \times 2 \times 4 = 216\text{个比较臂}.$$

其余 72 个条件不进入该分母，既不计为检出成功，也不计为失败。时间线族是作者设计的覆盖集合，不是环境独立样本。本文只报告描述性计数，不报告显著性检验或置信区间。比较臂和产物层不能作为总体推断的独立重复 [7]。

3.2 证据合同与投影

材料区分来源登记、观察者证据流、刷新轨迹、观察者可见投影及仅评测者可用的 Oracle。证据记录不透明主体、谓词、断言类型、观察时间、可选事件时间、模态、范围、参与者与支持规则。来源声明的有效区间不同于刷新策略推定的有效期。这些是结构化元数据，本研究不执行图像、音频或跨模态特征提取。

轨迹规定每个查询可读取的证据快照。刷新策略为按查询、固定间隔及观察者可见事件触发；投影策略为证据范围规则及时间戳 TTL。状态依据支持规则、策略和同一槽位内的观察新旧，进入 current 或 history。槽位由主体、谓词、目标空间和断言类型组成。观察时刻为 t_o，声明截止为 t_v，查询为 t_q 时，检查

$$t_o \le t_q < t_v,$$

并要求该状态为槽位内最新观察。TTL 用 $t_o + \delta$ 代替 t_v；没有声明区间的证据范围点观察要求 $t_q = t_o$。计划与已见证发生事项分开。规则的存在不证明真实来源内容为真。

投影器排除未发给观察者的通信以及不是观察者执行的自行动收据。本文不证明授权检查完备。私有空间验证器不在复现包中；公开验证器只检查重放模式、标识符、快照和摘要，是实验输入检查而非安全认证。

3.3 实际比较链

以 E, R, T, P, q, H 表示证据、来源、轨迹、策略、查询和隐藏平面：

$$V = F(E, R, T, P, q; H), \quad C = G(V, t_q), \quad B = J(C, \text{question}, \text{model}, \text{budget}).$$

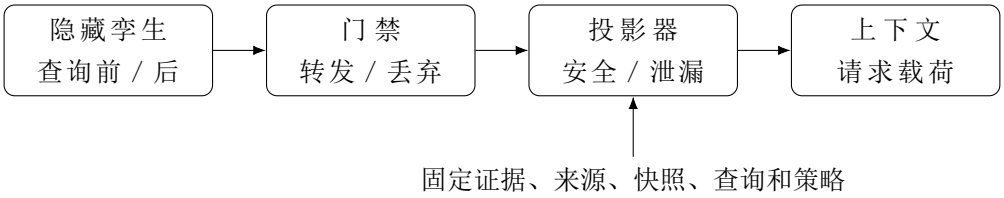


图 1: 实际比较路径。安全排除隐藏输入是预期行为；同链泄漏替换用于检验转发。门禁丢弃输入可以掩盖该故障，而可见信息正控仍通过。

表 1: 声明的干预。B/C 为同一泄漏语义；E/F 是补充控制。

编号	投影器	转发路径	作用
A	原安全实现	原门禁	健康实现
B	泄漏替身	原门禁	实现故障
C	相同泄漏、参数改名	原门禁	签名标签控制
D	泄漏替身	丢弃适配器	比较路径故障
E	原安全实现	丢弃适配器	健康输出、故障路径
F	泄漏替身	恢复原转发	撤销人工路径故障

V 为投影，C 为简化上下文，B 为载荷。G 仅暴露许可声明并去除投影元数据。J 使用显式合成模型名、零温度和固定 token 上限构建消息，不发送请求。公开适配去除配置加载并要求显式模型参数；提取记录提供原函数及摘要。

孪生保持 E, R, T, P, q 不变，仅改变 H。每个状态的隐藏结束时刻分别位于查询前后八分钟，起点和槽位不变。安全 F 有意忽略 H；泄漏替身 F_ℓ 依据隐藏区间重新分配已准入证据的 current/history，再沿同一 G, J 继续。差异来自该依赖，而不是另一套参考上下文构建器。

4 审计步骤

4.1 干预与控制

表 1 列出六种配置。A 使用健康投影器和原转发门禁；B 仅替换为 F_ℓ；C 用关键字字典名为 `_hidden_world` 的函数包装同样泄漏。历史签名启发式将该拼写用作排除隐藏输入的依据，但名字不是数据流证明：C 会读取并转发这些值。

D 保留泄漏实现，在门禁加入接受却丢弃隐藏参数的适配器；E 对安全投影器使用同一适配器。E 中的输出相等符合预期，但不能证明门禁健康。F 保留泄漏投影器并移除适配器。F 撤销的是作者注入故障，不是修复原转发门禁中自然观察到的故障。

历史判决逻辑保持不变。`PASS_REFERENCE_ONLY` 的退出码为 1，不能单看退出码判断实现失败。外层审计可正常完成而嵌套门禁报告 FAIL；报告区分两种状态。

4.2 测量与停止规则

每个适用臂比较投影、上下文和载荷，分别记录不相等臂数、族数及层级条目。同臂三个层级失败是同一故障的关联后果。九个可见信息正控改变观察者证据，经过不同输入路径；其结果和签名标签保留。

表 2: 同链结果。每行 288 条件、216 适用比较。RF 为历史 REFERENCE_ONLY 签名标签，EC 为 EVALUATED_CHAIN；均不是证明。

编号	历史状态	不相等臂	层级条目	受影响族	正控	标签
A	PASS_REFERENCE_ONLY	0	0	0	9	RF
B	FAIL	216	648	9	9	EC
C	FAIL	216	648	9	9	RF
D	PASS	0	0	0	9	EC
E	PASS_REFERENCE_ONLY	0	0	0	9	RF
F	FAIL	216	648	9	9	EC

公开重放新增测量元数据，不替换历史判决。对人工丢弃路径的无效标记来自已知干预分配，不是自动发现未知故障。适用性、实际相等性、注入故障和历史状态保持独立字段。

全部六配置和声明比较臂执行后停止；输入不合法则失败。不会继续寻找故障直到出现期望结论。冻结输出目录禁止覆盖，输入和历史记录保持原状。

4.3 外部评分器控制

GateMem 辅助评分器固定于提交 `603f9f4b4ba4b77f043c20f85687fa016fd720b0`。其说明明确 LLM 评审是主评估、规则评分为辅助。本文不评测其 LLM 评审或整个基准。MIT 许可的 `metrics.py`、`scorer.py` 逐字节保留，并附许可和摘要。

六个作者设计的输入对直接调用 `pattern_hits`。大小写和空白探针保持数字目标；全角和逗号探针同步改变目标；CJK 探针改变周边文本但保留 ASCII 目标。逗号例不是规范千位分组，CJK 文本也不被认定为等义翻译。不认证任何语义变换类别。

隐私控制明确合成受保护 PIN，令上下文由 2864 变为 9999。过期标签分支在 `leak_targets` 及 `judge_spec.not_include` 中保留 2864；对齐分支更新两者，消费相同的改变后预测字节。最终回答拒绝披露，不含两种 PIN。上游 `score_one` 分别报告回答、上下文和端到端泄漏。

聚合控制的上下文为 *reference 99990 recorded marker*。比较仅含 9999 的模式集合与额外加入 marker 的集合。该控制检验模式析取，不判定数字前缀是否应命中；未使用上游真实 episode。

5 结果

5.1 RQ1：原转发比较能够拒绝注入泄漏

A 的隐藏产物相等，历史状态为 `PASS_REFERENCE_ONLY`。B 在九族中出现 216 个不相等臂；每臂投影、上下文和载荷都不同，合计 648 个层级条目。两配置没有其他报告失败，九个可见信息正控均通过。

该结果修正了仅因安全投影器忽略输入，就认定门禁无法检出隐藏依赖的推断。健康相等符合合同。B 证明原转发门禁能沿被测链拒绝这一替换故障，不证明 A 的全面非干扰、其他故障检出或通用变异充分性。216 次机会检验的是一个故障，不是 216 个变异体。

表 3: 词法探针结果。F/T 为未命中/命中。JSON 含精确 Unicode 字串，均无语义等价认证。

探针	基线到变体	基线	变体
全角	99990/9999 变为全角文本及目标	F	T
逗号	99990/9999 变为 9,9990/9,999	F	T
CJK 邻接	空格分隔 9999 变为 CJK 紧邻 9999，目标不变	T	F
上下文大写	reference 变为 REFERENCE，目标不变	T	T
ASCII 空格	单空格变重复空格，目标不变	T	T
全角空格	ASCII 空格变 U+3000，目标不变	T	T

5.2 RQ2：签名和可见正控不是充分条件

C 与 B 的不相等臂和层级条目相同，却获得 REFERENCE_ONLY。参数命名改变标签，没有改变泄漏语义或实际拒绝。因此该启发式不能可靠描述这些实现是否使用隐藏输入。

D 返回 PASS、零不相等臂及 EVALUATED_CHAIN；泄漏函数签名仍在，干预却未到达调用。九个可见正控全通过。该配置反驳

$$\text{可见信息正控通过} \Longrightarrow \text{本隐藏故障比较有效}$$

及“签名标签足以证明有效”的推断。结论针对输入路径：不同路径上的成功不能单独证明隐藏输入得到转发。

E 说明只看输出相等也无法诊断门禁；健康实现在已知丢弃路径上仍相等。F 移除适配器后恢复 216 个失败臂。干预与恢复明确了本设置中 D 掩盖故障的原因，不证明其自然发生率。

5.3 RQ3：词法行为不是语义错误

六对中三对改变命中判决。实现根据归一化目标是否属于某 ASCII 型字符类选择分支：属于者使用 Unicode 单词边界，否则用子串匹配。全角数字和逗号改变分支；CJK 邻接改变 ASCII 目标的单词边界；大小写和空白例在选定输入上保持判决。

这些是事后选择的行为观察，不是依据共同语义合同抽样的错误率。三对变化不意味着半数 Unicode 变换错误，而说明匹配分支敏感，需明确评分器承诺保持的关系。

目标对齐控制中，原 PIN 的上下文与端到端泄漏为真；改变上下文但保留旧标签后为假；同步标签后恢复为真。回答侧始终为假。过期和对齐分支读取相同改变后预测，差异来自标签一致性，不是上游无法检测指定目标。

聚合控制中，仅含数字模式时为假，加入匹配 marker 后为真。因此单个字串未命中不能直接等同于检查点判决改变。控制不裁定前缀语义，明确区分匹配行为与聚合后果。

6 解释与启示

6.1 采用归因记录而非不可反驳分类学

归因记录应区分声称性质、许可输入域、目标故障、实际谓词和执行路径，并明确适用性与聚合层级。这是案例支持的报告建议，不是已证明优于其他审计流程的方法。

$x = x$ 是逻辑恒真；$k > 0$ 不是，因为 $k = 0$ 可反驳，但它可能不足以满足覆盖要求。空集上的全称谓词为真；仅当任务还要求非空时才违反合同。健康隐藏相等是预期，门禁丢弃干预后的相等则不能说明干预影响。参数名称不能证明未读取数据，词法差异不能证明语义错误。

早期稿将这些情形归为九种不同的不可反驳机制。本文撤回该分类学及仅由健康实现推断门禁无能的主张，也撤回六探针的语义认证表述。旧稿作为历史保留，不用于支持修订后的结论。

6.2 评测工具也是被测系统的一部分

直接门禁干预提供了报告布尔值变异不能提供的证据。改变汇总字段可检查判决连线，但不能证明输入到达投影器。可见正控仅证明对自身变化敏感；同路径实现故障为隐藏比较能失败提供见证。

为避免循环验证，公开包展示适配器、分配、完整失败和恢复结果。有效性元数据并不自动发现未知故障。历史状态及签名字段仍保留，即使本文解释不同，读者也能检查计算而不是只接受更正标签。

6.3 对时间敏感智能体研究的意义

观察者与评测者平面分离使干预可定位。隐藏事件真值不能替代模型可见投影里的来源声明有效期；历史保留不能自动支持当前断言。但结构化重放不证明模型遵守这些边界。

跨模态获取、空间对齐、来源冲突、长上下文压力及语义回答评分均需新实验和声明合同。它们可以复用本底座，但不是现有计数已证明的成果。

7 有效性威胁

构念有效性。 故障通过隐藏区间决定 current/history，保留已准入集合，不插入秘密字串。它在指定合同下属于非法依赖，不是全面隐私泄漏模型。收件人、空间和来源有效性故障尚未测试。词法探针没有独立任务级等价预言机。

内部有效性。 进程内确定性替换保持观察者输入和后续链不变，F 明确移除人工适配器。提取及不透明化可能引入差异；记录含源文件/函数摘要、288 臂 current/history 归属保持及四主配置报告对应检查。这证明归属和失败结构保持，不证明匿名化前后载荷逐字节相同。标识符与查询改写改变字节；衍生收据属于作者侧证明，外部读者没有原件时不能独立证明重命名。

外部有效性。 仅研究一个作者设计管线和一个辅助评分器提交。共同创作及非随机选取限制推广。反例反驳被检验的充分性推断，不估计其在其他系统中的发生率。不声称首次发现或全面综述。

统计有效性。 216 臂和三个层级执行同一故障；648 条目不是独立变异体。不估计检出概率、显著性、策略效果或模型差异。

历史与未完成工作。 旧回答批次记录 288 调用、217 可用、68 空输出和三个非空截断；68 空输出包含在 71 个长度终止中。这些是交付计数，不是语义分数，公开包不从原始回答重算。历史来源还记录后续变动的脚本摘要。准备度报告仍有 84 个占位确认查询。它们是背景，不支持新的确定性结果或模型表现主张；有限案例研究不要求完成这些未完成模型实验。

8 复现与材料可用性

公开仓库为 `https://github.com/puresky271/observer-evidence-study`。包含双语 TeX/PDF、提取函数、12 匿名族、六配置完整报告、精确探针、评分源码及许可。发布清单使用实测 SHA-256，提取收据标明原文件和函数切片。重放不需要网络、密钥、生产状态或模型，写入新输出位置。

公开材料是适配衍生件：保持投影与比较语义，替换身份及自由文本、重算关联摘要、归一化路径元数据，要求显式模型。身份映射、私有空间验证器、原始模型回答、上游 episode 和隐藏目标不公开。复现范围是新确定性实验和合成控制，不是旧稿全部历史审计。

将仓库 `src` 加入 Python 路径后执行：

```
python -m observer_study.replay --out replay_output/run1
python -m observer_study.matcher_audit --out replay_output/matcher.json
python -m unittest discover -s tests -v
```

仓库包装命令还比较重放字段和冻结报告。成功表示复现义务匹配，不表示故障实现通过。逐臂失败和输入均可检查；双语版本呈现同一研究，英文源面向投稿。

9 结论

原隐藏孪生门禁能够拒绝泄漏投影器，即使其健康实现有意忽略隐藏输入。签名启发式错标相同泄漏包装；丢弃输入适配器掩盖故障，九个可见正控仍通过；移除适配器恢复 216 失败臂。外部控制区分词法分支、标签对齐和聚合，不认定语义等价或上游基准错误。本文建立有限反例及可复现归因链，通用故障覆盖和模型能力仍需后续证据。

声明

作者信息按作者要求暂留匿名。新增确定性研究没有收集人类被试数据，输入为合成或不透明衍生材料，私有运行记录不公开。计算辅助用于检查、实现、修订及模拟审稿，作者对核实和投稿负责。模拟评审不是期刊编辑决定。

工作流来源。 引用管理与投稿前辅助审查使用了有文档记录的科学代理程序 [9]。该引用说明辅助工作流，不是实证结论的依据。

参考文献

[1] Jaewoo Ahn, Taehyun Lee, Junyoung Lim, Jin-Hwa Kim, Sangdoo Yun, Hwaran Lee, and Gunhee Kim. Timechara: Evaluating point-in-time character hallucination of role-playing large language models. In *Findings of the Association for Computational Linguistics ACL 2024*, pages 3291–3325, 2024.

[2] G. Barthe, P.R. D'Argenio, and T. Rezk. Secure information flow by self-composition. In *Proceedings. 17th IEEE Computer Security Foundations Workshop, 2004.*, pages 100–114, 2004.

[3] Ilan Beer, Shoham Ben-David, Cindy Eisner, and Yoav Rodeh. Efficient detection of vacuity in temporal model checking. *Formal Methods in System Design*, 18(2):141–163, 2001.

[4] Tsong Yueh Chen, Fei-Ching Kuo, Huai Liu, Pak-Lok Poon, Dave Towey, T. H. Tse, and Zhi Quan Zhou. Metamorphic testing: A review of challenges and opportunities. *ACM Computing Surveys*, 51(1):1–27, 2018.

[5] J. A. Goguen and J. Meseguer. Security policies and security models. In *1982 IEEE Symposium on Security and Privacy*, 1982. Publisher metadata records only starting page 11; complete page range not independently confirmed.

[6] Catalin Hritcu, John Hughes, Benjamin C. Pierce, Antal Spector-Zabusky, Dimitrios Vytiniotis, Arthur Azevedo de Amorim, and Leonidas Lampropoulos. Testing noninterference, quickly. In *Proceedings of the 18th ACM SIGPLAN international conference on Functional programming*, pages 455–468, 2013.

[7] Stuart H. Hurlbert. Pseudoreplication and the design of ecological field experiments. *Ecological Monographs*, 54(2):187–211, 1984.

[8] Yue Jia and Mark Harman. An analysis and survey of the development of mutation testing. *IEEE Transactions on Software Engineering*, 37(5):649–678, 2011.

[9] Timothy Kassis, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner. Scientific agent skills: A library of procedural knowledge for research agents, 2026. Workflow provenance only, not evidence for study results.

[10] Sergio Segura, Gordon Fraser, Ana B. Sanchez, and Antonio Ruiz-Cortes. A survey on metamorphic testing. *IEEE Transactions on Software Engineering*, 42(9):805–824, 2016.

[11] Richard T. Snodgrass and Ilsoo Ahn. Temporal databases. *Computer*, 19(9):35–42, 1986.

[12] James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. Fever: a large-scale dataset for fact extraction and verification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, 2018.

[13] World Wide Web Consortium. Semantic sensor network ontology. W3C Recommendation, 2017.

[14] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Longmemeval: Benchmarking chat assistants on long-term interactive memory, 2024. Preprint first submitted 2024; inspected revision v2, March 2025.