确定性智能体评测中的仪器侧失败归因

比较路径与匹配合同的重放研究

匿名作者
匿名单位

2026 年 10 月 14 日

摘要

智能体评测检查通过，可能源于实现正确、比较路径对故障不敏感，或实际谓词与声称性质不一致。这里的归因针对测量仪器，即检查是否本可失败，而不是定位导致任务失败的智能体或步骤。本文对观察者证据管线和固定版本的外部辅助评分器开展回顾性、无模型审计。在原门禁实际使用的投影、上下文与请求载荷链上注入一类作者设计的故障：投影器读取评测者独享的事件边界，即对隐藏输入的依赖，下文简称泄漏；随后干预门禁的输入转发。12 个合成时间线族包含 288 个嵌套条件，其中 216 个含状态断言的比较臂在三个产物层均拒绝该故障。仅改变故障函数的关键字参数名称，会改变基于签名的充分性标签，却不改变失败记录。相反，在门禁中丢弃扰动输入，会使每个比较两侧按构造完全相同，同一故障实现因此得到通过判决；门禁报告的任何信号，包括全部通过的九个可见信息正控，都无法把这次运行与健康运行区分开。恢复转发后，失败恢复。外部匹配器的六个词法探针对中有三个改变命中判决，但不据此认定语义等价或上游错误。目标字段对齐和评分聚合控制进一步区分匹配行为、标签一致性与检查点后果。本文贡献是包含健康、故障和恢复控制的可复现归因案例，以及由此整理的路径匹配控制清单；不是发生率或检出率估计、新的非干扰理论或语言模型质量评测。

关键词 智能体评测；仪器验证；故障注入；空洞性；非干扰测试；比较有效性；时间证据；可复现性

1 引言

智能体在动态环境中能够知道的内容，比世界的全局状态更窄。观察者离开房间后，房间可能已经安静；记得曾经听到声音，不等于能够断言现在仍有声音。评测既要区分观察者可获得的事实和评测者独享的事实，也要区分被测智能体的失败和测量工具的失败。用过期目标字段计算出的分数不能回答新目标的问题；没有收到干预输入的比较，也不能检验该干预的影响。

后一个区分是本研究的重点。近期智能体研究中的“失败归因”通常指在多智能体轨迹中定位导致任务失败的智能体与步骤 [7, 29]。本文取更窄的仪器侧含义：判断一次通过或失败的检查反映的是被测实现、比较门禁，还是附加在谓词上的解释。观察者证据项目的早期解释认为，安全投影器有意忽略隐藏输入，因此隐藏孪生输出相等的检查无法检出故障。该解释混淆了健康实现和比较门禁：门禁只要转发隐藏扰动，即使安全实现忽略它，也可能拒绝读取它的替换实现。本文在实际执行链上检验这种区别，不从函数签名推断检出能力。同一项目曾将外部匹配器的词法

差异描述为违反已认证表示等价性；输入材料并未建立这种认证。本文保留实测行为，收窄其解释。

研究对象是生成观察者可见投影、简化模型上下文和序列化请求载荷的确定性链。我们分别干预投影器及其调用门禁。固定版本的外部辅助评分器提供另一种归因问题，涉及词法匹配、目标标签及泄漏指标聚合。两部分均没有新增模型调用。

研究问题如下。**RQ1** 实际比较能否区分健康的隐藏状态不变性与依赖隐藏状态的投影器？**RQ2** 参数命名启发式及可见信息正控通过，是否足以证明隐藏故障比较有效？**RQ3** 没有独立语义关系或检查点后果证据时，匹配器探针对能够说明什么？

贡献包括：同链泄漏注入及健康、签名改名、输入丢弃和恢复控制；区分实现行为、干预传递和报告标签的归因分析，并由此整理五项路径匹配控制；公开源代码提取件、全部 12 族的不透明衍生夹具、逐比较报告和固定评分器的合成探针。输入丢弃配置是构造性反例：其通过判决由设计保证，价值在于显示门禁自身信号未能揭示什么。证据支持具体反例，不支持故障发生率、全面变异充分性、真实感知质量或模型排名。

2 背景与相关研究

2.1 时间与观察者证据

事实有效时间与系统获知时间的区分源于时间数据库研究 [23]。W3C 语义传感器网络本体区分现象时间与结果时间 [26]。本文将既有概念用于观察者时间线，不将时间有效性或来源追溯作为新概念。

LongMemEval 考查长期对话记忆中的时间推理、知识更新和弃答 [27]；TimeChara 考查特定时间点的角色知识 [2]。这些任务说明可获得证据与全局信息的区分具有应用意义。智能体记忆系统已经存储并检索带时间戳的证据：Zep 以时间知识图谱组织记忆 [20]，Mem0 与 A-MEM 维护并更新长期记忆 [9, 28]，T-Mem 利用时间结构恢复多方对话中的证据 [11]。这些系统以检索和回答质量评测。本文则检验模型能力评估前的确定性产物构建。三值可回答性同样不是新概念，FEVER 包含信息不足类别 [24]。本实现的投影器输出 current 和 history，unknown 可回答性仍在评测侧；本文没有实现完整三路回答机制。

2.2 非干扰、空洞性与基于故障的测试

非干扰限制不同信息域之间的影响 [10]；自组合通过成对执行分析关系性质 [4]，非干扰测试也有直接研究 [13]。隐藏孪生输出比较属于既有关系测试。有限执行能够给出反例，不能证明所有输入上的非干扰。

空洞性检测关注通过却未有效检验预期义务的规范 [5, 18]。模型检查中的形式定义不能无差别套用于一切弱检查。本文仅将指定输入域内恒真的谓词称为逻辑恒真；将干预在比较计算之前被丢弃称为比较输入路径失败。覆盖不足、阈值宽松和缺乏语义依据是不同问题。

变异测试考查测试对人为故障的响应 [15]，变异分析也是比较测试准则充分性的标准方法 [3]。本文采用这一思路，但不是代表性变异测试活动。只有一类泄漏投影语义和一类门禁故障；第二种签名包装相同泄漏语义。不同时间线比较臂是在不同输入上反复检验同一故障，不能计为独立变异体。

2.3　验证测量仪器

检验一个检查能否失败是老问题。Weyuker 讨论了缺乏实用预言机的程序 [25]。部分输入基线表明，基准可以在不使用其声称必需的输入时被解出 [19]；近期工作要求基准设计者探查所发布产物中的此类捷径 [6]。随机化检验显示，解释方法可能对其声称解释的模型不敏感 [1]；扰动检查也被用于揭示智能体数据分析管线中缺乏支持的结论 [21]。智能体基准实践本身也受到过审计 [16]。

最接近的先例是 Hill 对证据包验证器的变异研究 [12]。该文把沿未检查任何内容的路径报告成功的检查称为空洞通过，并测量可删除多少拒绝点而验证器的测试套件与篡改夹具仍全部通过。本文的门禁故障属于同一族。本文增加的内容更窄：隐藏孪生比较中的一对路径匹配故障。一个故障沿实际执行路径读取隐藏输入，比较必须失败；另一个在比较前丢弃该输入，并显示另一输入路径上的正控、签名标签和退出状态都不能揭示这种丢弃。本文不主张空洞性概念、用变异验证测试的做法，或“正控通过而被测性质未受检验”这一观察的首创性。

2.4　蜕变关系与评分合同

蜕变测试在缺乏传统预言机时检验相关输入输出的关系 [22, 8]。关系本身仍需依据。全角数字在某些任务中可能保留人类阅读含义；插入逗号或改变周边文本可能改变含义。整词匹配也可能是有意设计。判决变化不能单独决定哪一侧正确。

因此六个作者编写的成对输入被称为词法表示探针。本文另设明确受保护值的目标对齐控制，以及明确消费模式集合的聚合控制，避免将匹配器行为上升为公开基准分数错误。本文不声称提出新的变异框架，也不声称穷尽评测工具研究。

3　研究设计与对象

3.1　范围与选取

主要对象是一个项目既有的证据评测链、封存创作语料、孪生门禁及历史报告。研究是在报告解释受到质疑后选取的；故障、探针和分析在阅读实现后设计。本文是回顾性探索研究，没有预注册、随机选取被审计对象或留出故障集。“封存”仅表示语料此前已冻结，不使后续审计成为确认性研究。

12 个时间线族共享一个创作程序。九族具有状态断言及隐藏事件边界，三族为不适用该干预的通信族。每族包含三种刷新策略、两种投影策略和四个查询：

$$12 \times 3 \times 2 \times 4 = 288 \text{个嵌套条件}.$$

隐藏状态干预适用于九个状态族：

$$9 \times 3 \times 2 \times 4 = 216 \text{个比较臂}.$$

其余 72 个条件不进入该分母，既不计为检出成功，也不计为失败。时间线族是作者设计的覆盖集合，不是环境独立样本。本文只报告描述性计数，不报告显著性检验或置信区间。比较臂和产物层不能作为总体推断的独立重复 [14]。

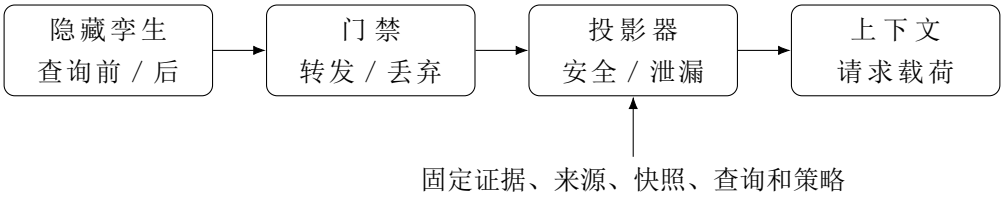


图 1: 实际比较路径。安全排除隐藏输入是预期行为；同链泄漏替换用于检验转发。门禁丢弃输入可以掩盖该故障，而可见信息正控仍通过。

3.2 证据合同与投影

材料区分来源登记、观察者证据流、刷新轨迹、观察者可见投影及仅评测者可用的 Oracle。证据记录不透明主体、谓词、断言类型、观察时间、可选事件时间、模态、范围、参与者与支持规则。来源声明的有效区间不同于刷新策略推定的有效期。这些是结构化元数据，本研究不执行图像、音频或跨模态特征提取。

轨迹规定每个查询可读取的证据快照。刷新策略为按查询、固定间隔及观察者可见事件触发；投影策略为证据范围规则及时间戳 TTL。状态依据支持规则、策略和同一槽位内的观察新旧，进入 current 或 history。槽位由主体、谓词、目标空间和断言类型组成。观察时刻为 t_o，声明截止为 t_v，查询为 t_q 时，检查

$$t_o \le t_q < t_v,$$

并要求该状态为槽位内最新观察。TTL 用 $t_o + \delta$ 代替 t_v；没有声明区间的证据范围点观察要求 $t_q = t_o$。计划与已见证发生事项分开。规则的存在不证明真实来源内容为真。

投影器排除未发给观察者的通信以及不是观察者执行的自行动收据。本文不证明授权检查完备。私有空间验证器不在复现包中；公开验证器只检查重放模式、标识符、快照和摘要，是实验输入检查而非安全认证。

3.3 实际比较链

以 E, R, T, P, q, H 表示证据、来源、轨迹、策略、查询和隐藏平面：

$$V = F(E, R, T, P, q; H), \quad C = G(V, t_q), \quad B = J(C, \text{question}, \text{model}, \text{budget}).$$

V 为投影，C 为简化上下文，B 为载荷。G 仅暴露许可声明并去除投影元数据。J 使用显式合成模型名、零温度和固定 token 上限构建消息，不发送请求。公开适配去除配置加载并要求显式模型参数；提取记录提供原函数及摘要。

孪生保持 E, R, T, P, q 不变，仅改变 H。每个状态的隐藏结束时刻分别位于查询前后八分钟，起点和槽位不变。隐藏平面由查询时刻合成：同一孪生内所有状态行获得相同的结束时刻，因此扰动是每个查询一次的全局翻转，且不携带任何秘密内容。安全 F 有意忽略 H；泄漏替身 F_ℓ 依据隐藏区间重新分配已准入证据的 current/history，再沿同一 G, J 继续。差异来自该依赖，而不是另一套参考上下文构建器。

表 1: 声明的干预。B/C 为同一泄漏语义；E/F 是补充控制。

编号	投影器	转发路径	作用
A	原安全实现	原门禁	健康实现
B	泄漏替身	原门禁	实现故障
C	相同泄漏、参数改名	原门禁	签名标签控制
D	泄漏替身	丢弃适配器	比较路径故障
E	原安全实现	丢弃适配器	健康输出、故障路径
F	泄漏替身	恢复原转发	撤销人工路径故障

4 审计步骤

4.1 干预与控制

表 1 列出六种配置。A 使用健康投影器和原转发门禁；B 仅替换为 F_ℓ；C 用关键字字典名为 `_hidden_world` 的函数包装同样泄漏。历史签名启发式将该拼写用作排除隐藏输入的依据，但名字不是数据流证明：C 会读取并转发这些值。

D 保留泄漏实现，在门禁加入接受却丢弃隐藏参数的适配器；E 对安全投影器使用同一适配器。E 中的输出相等符合预期，但不能证明门禁健康。F 保留泄漏投影器并移除适配器。F 撤销的是作者注入故障，不是修复原转发门禁中自然观察到的故障。

历史判决逻辑保持不变。`PASS_REFERENCE_ONLY` 的退出码为 1，不能单看退出码判断实现失败。外层审计可正常完成而嵌套门禁报告 FAIL；报告区分两种状态。

4.2 测量与停止规则

每个适用臂比较投影、上下文和载荷，分别记录不相等臂数、族数及层级条目。同臂三个层级失败是同一故障的关联后果。九个可见信息正控改变观察者证据，经过不同输入路径；其结果和签名标签保留。

公开重放新增测量元数据，不替换历史判决。对人工丢弃路径的无效标记来自已知干预分配，不是自动发现未知故障。适用性、实际相等性、注入故障和历史状态保持独立字段。

全部六配置和声明比较臂执行后停止；输入不合法则失败。不会继续寻找故障直到出现期望结论。冻结输出目录禁止覆盖，输入和历史记录保持原状。

4.3 外部评分器控制

GateMem 辅助评分器固定于提交 `603f9f4b4ba4b77f043c20f85687fa016fd720b0`。其说明明确 LLM 评审是主评估、规则评分为辅助。本文不评测其 LLM 评审或整个基准。MIT 许可的 `metrics.py`、`scorer.py` 逐字节保留，并附许可和摘要。

六个作者设计的输入对直接调用 `pattern_hits`。大小写和空白探针保持数字目标；全角和逗号探针同步改变目标；CJK 探针改变周边文本但保留 ASCII 目标。逗号例不是规范千位分组，CJK 文本也不被认定为等义翻译。不认证任何语义变换类别。

隐私控制明确合成受保护 PIN，令上下文由 2864 变为 9999。过期标签分支在 `leak_targets` 及 `judge_spec.not_include` 中保留 2864；对齐分支更新两者，消费相同的改变后预测字节。最

表 2: 同链结果。每行 288 条件、216 适用比较。RF 为历史 REFERENCE_ONLY 签名标签，EC 为 EVALUATED_CHAIN；均不是证明。

编号	历史状态	不相等臂	层级条目	受影响族	正控	标签
A	PASS_REFERENCE_ONLY	0	0	0	9	RF
B	FAIL	216	648	9	9	EC
C	FAIL	216	648	9	9	RF
D	PASS	0	0	0	9	EC
E	PASS_REFERENCE_ONLY	0	0	0	9	RF
F	FAIL	216	648	9	9	EC

终回答拒绝披露，不含两种 PIN。上游 `score_one` 分别报告回答、上下文和端到端泄漏。

聚合控制的上下文为 *reference 99990 recorded marker*。比较仅含 9999 的模式集合与额外加入 marker 的集合。该控制检验模式析取，不判定数字前缀是否应命中；未使用上游真实 episode。

5 结果

5.1 RQ1：原转发比较能够拒绝注入泄漏

A 的隐藏产物相等，历史状态为 `PASS_REFERENCE_ONLY`。B 在九族中出现 216 个不相等臂；每臂投影、上下文和载荷都不同，合计 648 个层级条目。两配置没有其他报告失败，九个可见信息正控均通过。

该结果修正了仅因安全投影器忽略输入，就认定门禁无法检出隐藏依赖的推断。健康相等符合合同。B 证明原转发门禁能沿被测链拒绝这一替换故障，不证明 A 的全面非干扰、其他故障检出或通用变异充分性。216 次机会检验的是一个故障，不是 216 个变异体。

5.2 RQ2：签名和可见正控不是充分条件

C 与 B 的不相等臂和层级条目相同，却获得 REFERENCE_ONLY。参数命名改变标签，没有改变泄漏语义或实际拒绝。因此该启发式不能可靠描述这些实现是否使用隐藏输入。

D 返回 PASS、零不相等臂及 EVALUATED_CHAIN。这一结果由构造保证：隐藏平面被丢弃后，每个孪生的两侧以相同参数调用同一函数，比较退化为 $x = x$（见第 6.1 节）。因此要点不是 D 通过，而是门禁报告的任何内容都无法把 D 与健康运行区分开：退出状态、签名标签和九个可见正控都与 A 或 E 相同。D 是针对

$$\text{可见信息正控通过} \Longrightarrow \text{本隐藏故障比较有效}$$

及“签名标签足以证明有效”这两项推断的构造性反例，说明推断无效，不说明此类门禁出现的频率。结论针对输入路径：不同路径上的成功不能单独证明隐藏输入得到转发。

E 说明只看输出相等也无法诊断门禁；健康实现在已知丢弃路径上仍相等。F 移除适配器后恢复 216 个失败臂。干预与恢复明确了本设置中 D 掩盖故障的原因，不证明其自然发生率。

表 3: 词法探针结果。F/T 为未命中/命中。JSON 含精确 Unicode 字串，均无语义等价认证。

探针	基线到变体	基线	变体
全角	99990/9999 变为全角文本及目标	F	T
逗号	99990/9999 变为 9,9990/9,999	F	T
CJK 邻接	空格分隔 9999 变为 CJK 紧邻 9999，目标不变	T	F
上下文大写	reference 变为 REFERENCE，目标不变	T	T
ASCII 空格	单空格变重复空格，目标不变	T	T
全角空格	ASCII 空格变 U+3000，目标不变	T	T

5.3 RQ3：词法行为不是语义错误

六对中三对改变命中判决。实现根据归一化目标是否属于某 ASCII 型字符类选择分支：属于者使用 Unicode 单词边界，否则用子串匹配。全角数字和逗号改变分支；CJK 邻接改变 ASCII 目标的单词边界；大小写和空白例在选定输入上保持判决。

这些是事后选择的行为观察，不是依据共同语义合同抽样的错误率。三对变化不意味着半数 Unicode 变换错误，而说明匹配分支敏感，需明确评分器承诺保持的关系。

目标对齐控制中，原 PIN 的上下文与端到端泄漏为真；改变上下文但保留旧标签后为假；同步标签后恢复为真。回答侧始终为假。过期和对齐分支读取相同改变后预测，差异来自标签一致性，不是上游无法检测指定目标。

聚合控制中，仅含数字模式时为假，加入匹配 marker 后为真。因此单个字串未命中不能直接等同于检查点判决改变。控制不裁定前缀语义，明确区分匹配行为与聚合后果。

6 解释与启示

6.1 采用归因记录而非不可反驳分类学

归因记录应区分声称性质、许可输入域、目标故障、实际谓词和执行路径，并明确适用性与聚合层级。这是案例支持的报告建议，不是已证明优于其他审计流程的方法。

$x = x$ 是逻辑恒真；$k > 0$ 不是，因为 $k = 0$ 可反驳，但它可能不足以满足覆盖要求。空集上的全称谓词为真；仅当任务还要求非空时才违反合同。健康隐藏相等是预期，门禁丢弃干预后的相等则不能说明干预影响。参数名称不能证明未读取数据，词法差异不能证明语义错误。

早期稿将这些情形归为九种不同的不可反驳机制。本文撤回该分类学及仅由健康实现推断门禁无能的主张，也撤回六探针的语义认证表述。旧稿作为历史保留，不用于支持修订后的结论。

6.2 评测工具也是被测系统的一部分

门禁层干预与报告布尔值变异检验的是不同环节。改变汇总字段可检查判决连线，但不能证明输入到达投影器。可见正控仅证明对自身变化敏感；同路径实现故障为隐藏比较能失败提供见证。本研究中两种变异方式的差别来自 D 的构造方式，并未作经验比较。

为避免循环验证，公开包展示适配器、分配、完整失败和恢复结果。有效性元数据并不自动发现未知故障。历史状态及签名字段仍保留，即使本文解释不同，读者也能检查计算而不是只接受更正标签。

6.3 路径匹配控制清单

对于声称隐藏或评测者独享输入不产生影响的比较，本案例提示五项检查。它们来自单一管线，尚未在其他门禁上验证。

1. 注入一个沿实际执行路径读取隐藏输入的实现故障，并要求比较失败。
2. 注入一个在比较计算前丢弃干预的门禁故障，检查报告记录的任何内容能否把它与健康运行区分开；若不能，应报告该比较未经验证，而不是通过。
3. 按输入路径报告正控；另一路径上的正控不能证明隐藏输入已送达。
4. 把签名和参数名当作文档，而不是数据流证据。
5. 移除每个注入故障后重跑，并在新标签旁保留历史判决。

6.4 对时间敏感智能体研究的意义

观察者与评测者平面分离使干预可定位。隐藏事件真值不能替代模型可见投影里的来源声明有效期；历史保留不能自动支持当前断言。但结构化重放不证明模型遵守这些边界。

跨模态获取、空间对齐、来源冲突、长上下文压力及语义回答评分均需新实验和声明合同。它们可以复用本底座，但不是现有计数已证明的成果。

7 有效性威胁

构念有效性。 故障通过隐藏区间决定 current/history，保留已准入集合，不插入秘密字串。隐藏平面由查询时刻合成，一个查询的所有状态结束时刻同时移动。因此本审计检验的是干预能否到达被比较的计算，而不是信息流泄漏率。“泄漏”指指定合同下的非法依赖，不是全面隐私泄漏模型。收件人、空间和来源有效性故障尚未测试。词法探针没有独立任务级等价预言机。

内部有效性。 进程内确定性替换保持观察者输入和后续链不变，F 明确移除人工适配器。提取及不透明化可能引入差异；记录含源文件/函数摘要、288 臂 current/history 归属保持及四主配置报告对应检查。这证明归属和失败结构保持，不证明匿名化前后载荷逐字节相同。标识符与查询改写改变字节；衍生收据属于作者侧证明，外部读者没有原件时不能独立证明重命名。

外部有效性。 仅研究一个作者设计管线和一个辅助评分器提交。共同创作及非随机选取限制推广。反例反驳被检验的充分性推断，不估计其在其他系统中的发生率。输入丢弃门禁由作者构造后又移除，本文没有对任何公开评测门禁做此类筛查，因此这类缺陷在实践中的发生频率未知。不声称首次发现或全面综述。

统计有效性。 216 臂和三个层级执行同一故障。由于每个孪生只施加一次全局翻转，这些比较臂是把同一扰动规则用于 216 个不同输入，而不是 216 种隐藏配置；648 条目也不是独立变异体。不估计检出概率、显著性、策略效果或模型差异。

历史与未完成工作。 旧回答批次记录 288 调用、217 可用、68 空输出和三个非空截断；68 空输出包含在 71 个长度终止中。这些是交付计数，不是语义分数，公开包不从原始回答重算。历史来源还记录后续变动的脚本摘要。准备度报告仍有 84 个占位确认查询。它们是背景，不支持新的确定性结果或模型表现主张；有限案例研究不要求完成这些未完成模型实验。

8 复现与材料可用性

公开仓库为 `https://github.com/puresky271/observer-evidence-study`。包含双语 TeX/PDF、提取函数、12 匿名族、六配置完整报告、精确探针、评分源码及许可。发布清单为每条公开路径记录 SHA-256，摘要按公开且平台无关的构造计算：UTF-8 文本统一为 LF 换行后计算，其他文件按原字节计算，目录只包含 git 会发布的文件。旧构造直接计算工作区原始字节，同一提交在 Windows 与 Linux 检出上得到不同摘要；持续集成现在在两种系统上重新测量清单。提取收据标明原文件和函数切片。去标识扫描器的公开自测只使用虚构词条，因为真实禁用词表不公开；公开运行因此不能证明私有标识符不存在。重放不需要网络、密钥、生产状态或模型，写入新输出位置。

公开材料是适配衍生件：保持投影与比较语义，替换身份及自由文本、重算关联摘要、归一化路径元数据，要求显式模型。身份映射、私有空间验证器、原始模型回答、上游 episode 和隐藏目标不公开。复现范围是新确定性实验和合成控制，不是旧稿全部历史审计。

将仓库 `src` 加入 Python 路径后执行：

```
python -m observer_study.replay --out replay_output/run1
python -m observer_study.matcher_audit --out replay_output/matcher.json
python -m unittest discover -s tests -v
```

仓库包装命令还比较重放字段和冻结报告。成功表示复现义务匹配，不表示故障实现通过。逐臂失败和输入均可检查；双语版本呈现同一研究，英文源面向投稿。

9 结论

原隐藏孪生门禁能够拒绝泄漏投影器，即使其健康实现有意忽略隐藏输入。签名启发式错标相同泄漏包装；丢弃输入适配器按构造掩盖故障，而门禁报告的任何内容，包括九个通过的可见正控，都未揭示这种掩盖；移除适配器恢复 216 失败臂。外部控制区分词法分支、标签对齐和聚合，不认定语义等价或上游基准错误。本文建立有限反例、可复现归因链和路径匹配控制清单。由于没有筛查任何公开门禁，输入丢弃门禁在实践中的发生频率未知；通用故障覆盖和模型能力仍需后续证据。

声明

作者信息按作者要求暂留匿名。新增确定性研究没有收集人类被试数据，输入为合成或不透明衍生材料，私有运行记录不公开。计算辅助用于检查、实现、修订及模拟审稿，作者对核实和投稿负责。模拟评审不是期刊编辑决定。

工作流来源。 引用管理与投稿前辅助审查使用了有文档记录的科学代理程序 [17]。该引用说明辅助工作流，不是实证结论的依据。

参考文献

[1] Julius Adebayo, Justin Gilmer, Michael Muelly, Ian Goodfellow, Moritz Hardt, and Been Kim. Sanity checks for saliency maps. arXiv:1810.03292, 2018.

[2] Jaewoo Ahn, Taehyun Lee, Junyoung Lim, Jin-Hwa Kim, Sangdoo Yun, Hwaran Lee, and Gunhee Kim. TimeChara: Evaluating point-in-time character hallucination of role-playing large language models. In *Findings of the Association for Computational Linguistics ACL 2024*, pages 3291–3325, 2024.

[3] James H. Andrews, Lionel C. Briand, Yvan Labiche, and Akbar Siami Namin. Using mutation analysis for assessing and comparing testing coverage criteria. *IEEE Transactions on Software Engineering*, 32(8):608–624, 2006.

[4] G. Barthe, P.R. D'Argenio, and T. Rezk. Secure information flow by self-composition. In *Proceedings. 17th IEEE Computer Security Foundations Workshop, 2004.*, pages 100–114, 2004.

[5] Ilan Beer, Shoham Ben-David, Cindy Eisner, and Yoav Rodeh. Efficient detection of vacuity in temporal model checking. *Formal Methods in System Design*, 18(2):141–163, 2001.

[6] Ellis Brown, Jihan Yang, Shusheng Yang, Rob Fergus, and Saining Xie. Benchmark designers should "train on the test set" to expose exploitable non-visual shortcuts. arXiv:2511.04655, 2025. COLM 2026, per the arXiv record.

[7] Mert Cemri, Melissa Z. Pan, Shuyi Yang, Lakshya A. Agrawal, Bhavya Chopra, Rishabh Tiwari, Kurt Keutzer, Aditya Parameswaran, Dan Klein, Kannan Ramchandran, Matei Zaharia, Joseph E. Gonzalez, and Ion Stoica. Why do multi-agent LLM systems fail? arXiv:2503.13657, 2025.

[8] Tsong Yueh Chen, Fei-Ching Kuo, Huai Liu, Pak-Lok Poon, Dave Towey, T. H. Tse, and Zhi Quan Zhou. Metamorphic testing: A review of challenges and opportunities. *ACM Computing Surveys*, 51(1):1–27, 2018.

[9] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready AI agents with scalable long-term memory. arXiv:2504.19413, 2025.

[10] J. A. Goguen and J. Meseguer. Security policies and security models. In *1982 IEEE Symposium on Security and Privacy*, 1982. Publisher metadata records only starting page 11; complete page range not independently confirmed.

[11] Junyou Guo, Chongyang Tao, Yan He, Yong Wang, and Shuai Ma. Temporal evidence forests for long-horizon multi-party conversational memory. arXiv:2610.12874, 2026.

[12] Erik Hill. Four ways to forge a bundle my own verifier calls clean: Refusal-site mutation testing of an evidence-bundle verifier. arXiv:2608.26183, 2026.

[13] Catalin Hritcu, John Hughes, Benjamin C. Pierce, Antal Spector-Zabusky, Dimitrios Vytiniotis, Arthur Azevedo de Amorim, and Leonidas Lampropoulos. Testing noninterference, quickly. In *Proceedings of the 18th ACM SIGPLAN international conference on Functional programming*, pages 455–468, 2013.

[14] Stuart H. Hurlbert. Pseudoreplication and the design of ecological field experiments. *Ecological Monographs*, 54(2):187–211, 1984.

[15] Yue Jia and Mark Harman. An analysis and survey of the development of mutation testing. *IEEE Transactions on Software Engineering*, 37(5):649–678, 2011.

[16] Sayash Kapoor, Benedikt Stroebl, Zachary S. Siegel, Nitya Nadgir, and Arvind Narayanan. AI agents that matter. arXiv:2407.01502, 2024.

[17] Timothy Kassis, Vinayak Agarwal, Yuhuan He, Darshil Patel, and Aubrey M. Brueckner. Scientific agent skills: A library of procedural knowledge for research agents, 2026. Workflow provenance only, not evidence for study results.

[18] Orna Kupferman and Moshe Y. Vardi. Vacuity detection in temporal model checking. *International Journal on Software Tools for Technology Transfer*, 4(2):224–233, 2003.

[19] Adam Poliak, Jason Naradowsky, Aparajita Haldar, Rachel Rudinger, and Benjamin Van Durme. Hypothesis only baselines in natural language inference. arXiv:1805.01042, 2018. *SEM 2018, per the arXiv record.

[20] Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. arXiv:2501.13956, 2025.

[21] Zachary T. Rewolinski, Austin V. Zane, Hao Huang, Chandan Singh, Chenglong Wang, Jianfeng Gao, and Bin Yu. Sanity checks for agentic data science. arXiv:2604.11003, 2026.

[22] Sergio Segura, Gordon Fraser, Ana B. Sanchez, and Antonio Ruiz-Cortes. A survey on metamorphic testing. *IEEE Transactions on Software Engineering*, 42(9):805–824, 2016.

[23] Richard T. Snodgrass and Ilsoo Ahn. Temporal databases. *Computer*, 19(9):35–42, 1986.

[24] James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. Fever: a large-scale dataset for fact extraction and verification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, 2018.

[25] Elaine J. Weyuker. On testing non-testable programs. *The Computer Journal*, 25(4):465–470, 1982.

[26] World Wide Web Consortium. Semantic sensor network ontology. W3C Recommendation, 2017.

[27] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. LongMemEval: Benchmarking chat assistants on long-term interactive memory. arXiv:2410.10813, 2024. ICLR 2025, per the arXiv record; inspected revision v2, March 2025.

[28] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-MEM: Agentic memory for LLM agents. arXiv:2502.12110, 2025. NeurIPS 2025, per the arXiv record.

[29] Shaokun Zhang, Ming Yin, Jieyu Zhang, Jiale Liu, Zhiguang Han, Jingyang Zhang, Beibin Li, Chi Wang, Huazheng Wang, Yiran Chen, and Qingyun Wu. Which agent causes task failures and when? on automated failure attribution of LLM multi-agent systems. arXiv:2505.00212, 2025.